

De la un jurnal la mai multe: detectarea și generalizarea schimbărilor de stil asociate GenAI în scrierea academică

Bonciu Vlad-Matei

Coordonatori științifici:

lect. univ. dr. Doinea-Zurini Mădălina & lect. univ. dr. Gheorghe Mihai

Academia de Studii Economice București, Facultatea de Cibernetică, Statistică și Informatică Economică

Problema detectării textului generat cu ajutorul modelelor de limbaj începe să fie una care vizează întregul mediu online. Poluarea surselor de informație digitale duce la pierderea încrederii publicului în informațiile vaste disponibile și poate contribui la polarizarea societății. Integritatea academică este una din zonele care are cel mai mult de suferit din cauza acestui nou fenomen. Abordăm problema identificării textului sintetic prin intermediul indicatorilor stilometrici, care oferă un grad înalt de interpretabilitate față de modelele de tip "black-box". Analiza noastră se axează pe abstracte din diferite surse academice, cât și un corpus de paragrafe rescrise cu ajutorul unui model de limbaj mare. Utilizăm acești indicatori ai stilului concomitent pentru a extrage schimbările de redactare în era post-AI. În urma analizei noastre putem concluziona faptul că textele scrise după apariția acestor modele de limbaj prezintă un stil care corespunde în mare măsură cu cel asociat utilizării AI-ului generativ. Oferim astfel o perspectivă diferită asupra metodelor de detectare a textului sintetic.

The problem of detecting text generated using language models is beginning to be one that targets the entire online environment. Pollution of digital information sources leads to loss of public trust in the vast amount of available information and can contribute to the polarization of society. Academic integrity is one of the areas that suffers the most from this new phenomenon. We address the problem of identifying synthetic text through stylometric indicators, which offer a high degree of interpretability compared to "black-box" type models. Our analysis focuses on abstracts from different academic sources, as well as a corpus of paragraphs rewritten using a large language model. We use these style indicators simultaneously to extract shifts in writing style in the post-AI era. Following our analysis, we can conclude that texts written after the emergence of these language models present a style that largely corresponds to that associated with the use of generative AI. We thus offer a different perspective on a different method for detecting synthetic text.

1. Introducere

Lansarea actuală a mai multor modele de limbaj avansate, precum GPT-5.4, Claude Opus 4.6, Kimi K2.5, a condus la democratizarea accesului la generarea de text sintetic. Aceste modele de inteligență artificială (engl. Artificial Intelligence (AI)) sunt capabile să genereze documente complexe, să răspundă la întrebări, adesea cu capacități asemănătoare celor umane ([Schulman et al., 2022](#)). Astfel, în acest moment există o problemă privind "poluarea" surselor informaționale din mediul online datorită accesului facil la aceste modele. Când informațiile nu sunt integral verificate pentru validitate înainte de a fi propagate în continuare, se pot perpetua foarte ușor halucinații sau bias-uri tipice AI-ului generativ (GenAI). Integritatea academică reprezintă una dintre mizele majore în dezvoltarea unor metode capabile să identifice textul sintetic generat de către modelele de limbaj.

Scopul nostru în cadrul acestui studiu este de a identifica dacă stilul scriitorilor de articole academice a fost influențat în mod direct sau indirect de către noul mediu actual, unde textul generat de modelele de limbaj mari (engl. Large Language Models (LLM)) este din ce în ce mai des întâlnit.

Vom aborda schimbările stilistice prin măsurarea unor indicatori din lingvistică computațională (engl. computational linguistics) și subdomeniile aferente acestora. În scopul acestei distincții între stilistica scrisă de om și cea generată de un model, noi abordăm problema prin măsurarea unor indicatori interpretabili, în contrast cu modelele de tip “black-box” utilizate recent. Ne dorim astfel ca, utilizând metodele prezentate ulterior, să fie întocmite noi modele pentru care se pot justifica deciziile luate datorită acestui aspect.

Studiul nostru este important deoarece prezintă o perspectivă diferită din care poate fi văzută problema detectării textului generat cu LLM-uri. De asemenea prezentăm faptul că stilistica în era post-AI se îndreaptă către trăsăturile întâlnite în textul GenAI.

Întrebările de cercetare propuse sunt:

- RQ1. Cum s-a schimbat stilul de redactare a abstractelor în era post-AI?
- RQ2. Care sunt indicatorii care înregistrează cele mai mari schimbări stilistice?
- RQ3. În ce măsură corespund schimbările stilistice din era post-AI cu cele asociate utilizării GenAI?

2. Revizuirea literaturii de specialitate

În lucrarea “Stylometric Detection of AI-Generated Text in Twitter Timelines” o grupă de cercetători din cadrul Arizona State University a realizat o analiză stilistică între textul uman și cel generat sintetic. Echipa utilizează o suită de indicatori frazeologici, lexicali și de punctuație, printre care sunt regăsiți și Moving Average Type Token Ratio (MATTR), diversitatea și densitatea punctuației ([Kumarage et al., 2023](#)). Cu ajutorul acestor trăsături sunt antrenate multiple modele pentru detectarea textului GenAI. Performanța acestora este comparată ulterior cu cea a modelelor bazate pe arhitectura de encoder (BERT, RoBERTa), de tip XGBoost și cele de tip Word2Vec. Rezultatele dintre noile metode propuse și cele existente deja sunt similar, avantajul noilor implementări fiind interpretabilitatea adusă. De asemenea este de remarcat faptul că analiza decurge pe un set de date cu un cadru informal, postări X (Twitter).

În anul 2024, doi cercetători au publicat lucrarea “Unveiling ChatGPT text using writing style”, unde se realizează o analiză dintre performanțele a diferite modele de clasificare între text uman și sintetic. Indicatorii utilizați ca și date de intrare în aceste modele țin de diversitate lexicală, trăsături gramaticale și trăsături de punctuație. În urma acestei analize rezulta faptul că modelele cele mai eficiente sunt cele de XGBoost ([Berriche and Larabi-Marie-Sainte, 2024](#)). Un potențial dezavantaj al acestui studiu ar fi faptul că este utilizat un număr foarte mare de trăsături per paragraf (34 de indicatori diferiți), fapt ce ar putea duce la o rarefiere a setului de date într-un spațiu cu atât de multe dimensiuni (“Curse of Dimensionality”).

Doi cercetători din cadrul University of Miskolc au realizat o analiză comprehensivă asupra articolelor academice și variantele parafrazate ale acestora utilizând un model de limbaj (GPT-4). În cadrul analizei sunt folosiți indicatori care se bazează pe etichetarea părților de vorbire (engl. part of speech tagging (POS)) din cadrul propozițiilor, cu ajutorul cărora aceștia construiesc arbori de dependență la nivel de propoziție ([Varga and Baksa, 2025](#)). De asemenea, se realizează o comparație între distribuțiile de frecvență pentru fiecare parte de vorbire analizată pentru textele umane și cele GenAI. În analiză mai sunt utilizați și alți indicatori stilistici clasici, precum Mean Dependency Distance. Un punct slab al acestui studiu este faptul că toate abstractele parafrazate au aceeași origine, fără să fie ținut cont de diferitele niveluri de constrângere a tehnoredactării aferente scrierii academice.

În anul 2025, o echipă de cercetători din Franța a publicat în cadrul asociației pentru lingvistică computațională un articol care realizează o analiză comprehensivă asupra diversității textelor la nivel lexical, sintactic și semantic. Este utilizat un set de date divers, format din conversații “multi-turn” între persoane și modele de limbaj ([Guo et al., 2025](#)). Analiza utilizează diverse modele de limbaj de diferite mărimi pentru a distinge trăsăturile stilistice în funcție de mărimea LLM-urilor. În final, se realizează o corelație dintre rezultatele aferente celor 3 categorii de indicatori statistici studiați, din care se poate extrage faptul că există o corelație moderată între trăsăturile semantice și cele sintactice. O slăbiciune a studiului poate fi cadrul informal din care au fost extrase conversațiile (Twitter, dialog text informal, etc.).

În urma analizei literaturii de specialitate, lacuna identificată ar fi lipsa de comparare a textelor umane la diferite niveluri de formalitate, nu doar cu textul GenAI. Scopul acestei propuneri ar fi cel de a vedea schimbările stilistice ale indicatorilor, atât la nivelul modificării cadrului formal, cât și la nivelul textului sintetic.

3. Metodologie

Privind acest studiu am ales să abordăm subiectul dintr-o perspectivă cantitativă. Modul nostru de lucru are în vedere trei perioade de analiză: o perioadă de bază la care ne vom raporta, un an intermediar care este ignorat în anumite analize și o perioadă curentă. Perioada de bază este reprezentată de intervalul de timp al anilor 2018-2021, iar cea curentă este dată de anii 2023-2026. Ne așteptăm să existe o consistență în distribuțiile indicatorilor utilizați pentru perioadele de bază și cea curentă, iar în anul 2022, anul intermediar ales, să vedem o interpolare dintre aceste două distribuții. De asemenea, am restrâns scopul studiului în analiza datelor aferente unui singur domeniu: informatica (engl. computer science), în scopul eliminării de tendințe privind stilistica sau redactarea lucrărilor. Tot corpusul de texte abordat este în limba engleză atât pentru ușurința construirii seturilor de date, cât și pentru că este un limbaj internațional utilizat des în redactarea lucrărilor academice. Am ales punctul de inflexiune anul 2022 datorită lansării platformei ChatGPT în acel an, astfel considerăm că era post-AI începe din acest punct.

Am ales să realizăm analiza schimbărilor stilistice în domeniul scrierii academice la nivel de abstract din mai multe considerente. Un prim aspect de care trebuie ținut cont este faptul că fiecare jurnal poate avea condiții de tehnoredactare diferite, fapt care ar putea afecta consistența datelor extrase. Condiționarea, de exemplu, a expunerii metodologiei după rezultate poate duce la o expunere a ideilor într-un mod diferit față de o prezentare a acestora pre-rezultate. Un alt considerent pentru această alegere ar fi faptul că abstractele urmează un tipar predictibil, unde sunt prezentate pe scurt: problematica abordată, metodologia, datele analizate, rezultatele principale și contribuția lucrării în domeniu. Astfel, folosind abstractele nu doar că scăpăm de inconsistențele date de criteriile de redactare ale jurnalelor, ci și dobândim o expunere de ansamblu asupra lucrării.



Fig. 1
Ilustrare a seturilor de date utilizate în aceasta analiza. Seturile de date “Q1” și “Arxiv” includ perioadele de baza, curentă și cea intermediară. Setul de date “Human vs AI” conține paragrafe din Wikipedia și varianta lor parafrazată de GenAI

Categoriile pe care am ales să realizăm analiza sunt următoarele 3 seturi de date: articolele aferente jurnalului “*INFORMATION FUSION*” (referit din acest punct ca și “*Q1*”), un set de articole din categoria de Computer Science de pe platforma ArXiv (referit din acest punct ca și “*ArXiv*”) și un set de paragrafe Wikipedia în forma lor originală, cât și într-o formă parafrazată de un model de limbaj avansat (GPT 5 Nano) (referit din acest punct ca și “*Human vs AI*”).

Am ales jurnalul pentru clasificarea acestuia în prima quartilă (Q1) în baza de date Web Of Science (WoS) în categoriile “*COMPUTER SCIENCE, ARTIFICIAL INTELLIGENCE*” și “*COMPUTER SCIENCE, THEORY & METHODS*”, fapt care arată o implicită rigurozitate privind procesul de recenzie pentru publicare. Setul de date “ArXiv” a fost ales pentru a observa dinamica stilistică în absența constrângerilor editoriale formale, oferind o perspectivă asupra textului în stadiul de preprint. Astfel, prezentăm o comparație relevantă cu jurnalul de elită, unde lucrarea este supusă unui proces de rafinare succesiv și există o calibrare riguroasă a limbajului academic. Corpusul de texte “Human vs AI” a fost ales atât pentru cadrul formal, sec, similar articolelor academice în care scriitorii Wikipedia prezintă ideile, dar mai ales pentru a vedea dacă exista o schimbare stilistică remarcabilă în parafrázările modelelor de limbaj. Considerăm că paragrafele originale de pe platforma Wikipedia au o probabilitate foarte mică de a fi generate cu modele de limbaj datorită politicilor stricte privind gestionarea textului sintetic, cât și datorită noii inițiative din partea comunității de autori “WikiProject AI Cleanup” ([Wikipedia, 2026](#)).

SO=(INFORMATION FUSION) AND PY=(2018-2026) AND DT=(Article) (1)

Seturile de date trec printr-un pas de preprocesare care impune un număr egal de abstracte pentru fiecare an analizat. Pentru a atinge acest scop, folosim mediana frecvențelor de articole publicate pentru fiecare an ca și prag superior.

Pentru o analiză comprehensivă a stilului redactării lucrărilor, am ales să ne concentrăm pe indicatori lexicali, sintactici, de punctuație și stilistici. Cu ajutorul următorilor nouă indicatori, sperăm să capturăm o plajă diversă de măsurători necesare pentru distingerea stilului cu care sunt redactate abstractele.

Categorie	Indicatori
Diversitate Lexicală	<i>MATTR, MTLT, Indexul Gini Simpson</i>
Diversitate Sintactică	<i>Burstiness, Coeficientul Gini în lungimea propozițiilor</i>
Punctuație	<i>Densitatea punctuației, Diversitatea punctuației</i>
Stilistică	<i>Function Word Ratio, Mean Dependency Distance, Rata vocii pasive</i>

Moving Average TTR (MATTR) este un indicator pentru măsurarea diversității lexicale în cadrul unui text. Type Token Ratio (TTR) este calculat pentru intervale de 50 cuvinte, apoi este calculată media valorilor rezultate. Acesta este remarcat ca fiind mai independent de lungime decât TTR clasic. Ecuația pentru TTR este:

$$TTR = \text{nr_cuvinte_unice} / \text{nr_total_cuvinte} \quad (2)$$

Measure of Textual Lexical Diversity (MTLD) este un alt indicator foarte recomandat pentru măsurarea diversității lexicale ([McCarthy & Jarvis, 2010](#)). Este util tot din perspectiva independenței față de lungimea textului.

Indexul Gini Simpson pentru diversitate lexicală este ultimul indicator utilizat pentru diversitate lexicală care se bazează pe formula lui Simpson pentru stabilirea diversității lexicale:

$$\text{Diversitate} = 1 - \left(\sum n(n-1) / N(N-1) \right) \quad (3)$$

n = frecvența unui cuvânt specific ; N = numărul total de cuvinte

Function Word Ratio măsoară ce procent din paragraf este utilizat pentru a lega conceptele. Practic este o metodă de a cuantifica cât de mult sunt folosite cuvinte pentru conținut față de cuvinte care leagă conținut. Cuvintele funcționale în limba engleză sunt reprezentate de: determinanți și pre-determinanți (*the, all*), numerale cardinale (*one, two*), prepoziții și conjuncții (*in, and, but*), particula „to”, particule adverbiale (*up, out*), auxiliare modale (*can, would*), pronume personale și posesive (*I, my*), cuvinte interogative (*which, who, whose, where*), „there” existențial și interjecții (*oh, well*). Astfel, vedem indirect cât de multă substanță conține o propoziție, eliminând lungimea exprimării:

$$\text{FuncWordRatio} = \text{nr_cuvinte_functionale} / \text{nr_cuvinte_totale} \quad (4)$$

Coeficientul de variație al lungimii propozițiilor (Burstiness) este un indicator sintactic des utilizat în detectarea textului generat cu modele de limbaj mari. Textul uman are de obicei lungimi de propoziții care variază puternic de la o propoziție la alta, aspect pe care modelele de limbaj actuale nu reușesc să-l reproducă fidel (lungimile de propoziții sunt anormal de uniforme). Propozițiile sunt măsurate în cuvinte.

$$\text{Burstiness} = \sigma / \mu \quad (5)$$

σ = abaterea standard a lungimii propozițiilor ; μ = media lungimii propozițiilor

Coeficientul Gini măsoară inegalitatea în lungimea propozițiilor. Acesta este de obicei utilizat în economie, unde măsoară inegalitatea veniturilor, dar poate fi utilizat și ca un indicator sintactic în contextul prezentat.

$$G = (2 \sum i \cdot l_i) / (n \sum l_i) - (n+1)/n \quad (6)$$

i - rangul propoziției din paragraf ; l_i - lungimea propoziției i din paragraf

Densitatea punctuației indică frecvența cu care sunt utilizate semne de punctuație față de totalul cuvintelor și punctuației folosite.

$$\text{Densitate} = \text{nr_semne_punct} / (\text{nr_cuvinte_totale} + \text{nr_semne_punct}) \quad (7)$$

Indexul Gini Simpson pentru diversitate a punctuației măsoară diversitatea de semne de punctuație utilizate. Acest indicator este utilizat de obicei în detectarea autorului unui text.

$$\text{Diversitate} = 1 - \left(\sum n(n-1) / N(N-1) \right) \quad (8)$$

n - numărul de apariții a unui semn specific (eg. ‘-’); N - numărul de semne punctuație în total

Mean Dependency Distance (MDD) măsoară distanțele medii între fiecare cuvânt dintr-o propoziție și respectivul cuvânt la care acesta se referă. Măsoară efortul cognitiv pe care un

cititor l-ar avea în momentul lecturii textului. Acesta se măsoară la nivel de propoziție. Pentru a avea o singură valoare numerică la nivel de paragraf vom calcula *coeficientul de variație* al măsurătorilor pentru fiecare propoziție:

$$\text{CoefVar_MDD} = \sigma / \mu \quad (9)$$

σ = abaterea standard a MDD-ului propozițiilor ; μ = media MDD-ului propozițiilor

Rata vocii pasive (engl. *Passive Voice Rate*) este un indicator stilistic utilizat des în identificarea autorului unui text. O propoziție pasivă este identificată prin: auxiliar „fi” (conjugat) + participiu trecut (VBN), urmat opțional de expresia „de”. Această abordare este adesea folosită pentru a crea un sentiment fals de obiectivitate sau pentru a masca actorul într-o propoziție (de exemplu, „Decizia a fost luată” în loc de „Am luat decizia”).

$$\text{PVRate} = \text{nr_propozitii_pasive} / \text{nr_propozitii_totale} \quad (10)$$

Pentru analiza noastră, toți acești indicatori vor fi agregați într-un singur vector numeric, așezați în ordinea prezentării ulterioare. Acest vector caracteristic, calculat pentru fiecare paragraf, va fi subiectul analizei noastre în continuare.

$$v = [\text{MATTR}, \text{MTLD}, \dots, \text{Burstiness}, \dots] \in \mathbb{R}^{10} \quad (11)$$

În continuare, pentru fiecare set de date menționat anterior, am trecut printr-un pas de procesare. Datele sunt normalizate utilizând Scoruri Z la nivel de indicator.

Pentru evaluarea acestor noi puncte de date am ales să realizăm o analiză a componentelor principale (ACP) (engl. Principal Component Analysis (PCA)) pentru a extrage variația maximă agregată din indicatori, în scopul obținerii unor grupări (engl. clusters) în proiecțiile 2-dimensionale și 3-dimensionale. De asemenea, la nivel de set de date am realizat analiza asupra distribuțiilor în perioada de bază și cea curentă (histograme) pentru fiecare element din vectorul de trăsături.

Ulterior încercăm să aplicăm metode de justificare a unor grupări prin următoarele metode statistice. Utilizăm analiza de decalaj (engl. Gap Statistics) pentru identificarea unui număr K optim pentru clusterizare de tip K-Medii (engl. K-Means). În cazul în care K -ul rezultat în urma analizei de decalaj este mai mare decât 1, adică sunt identificate grupări de puncte de date relevante din punct de vedere statistic, vom aplica metoda Silhouette. Silhouette este o metodă de interpretare și validare a coerenței punctelor în cadrul grupurilor de date.




Fig. 2
Reducerea de dimensionalitate dintr-un spațiu tridimensional într-unul unidimensional cu ajutorul PCA

4. Rezultate

Primul pas impus în metodologia noastră a fost cel de preprocesare a datelor, care implică uniformizarea numărului de articole analizate pentru fiecare perioadă. Datele obținute în final au fost următoarele:

Setul de date	Numărul de puncte de date obținute			
	2018-2021 (pre-AI)	2022	2023-2026 (post-AI)	Total
Q1	512	125	592	1229
ArXiv	1995	498	1996	4489
Setul de date	Paragrafe originale	Paragrafe parafrazate (GPT-5-Nano)		Total
Human vs AI	4086	4086		8172

După normalizarea datelor, primul calcul efectuat în analiza noastră este coeficientul de corelație Pearson între fiecare indicator utilizat. Astfel, obținem o matrice de corelație care explică legături ascunse între diferitele măsurători.




Fig. 3 Matricea de corelație pentru setul de date "ArXiv"

Rezultatele obținute scot în evidență mai multe tipare la care ne puteam aștepta, dar și unele mai atipice. Cea mai proeminentă valoare observată ar fi corelația dintre indicatorii Burstiness și Indicatorul Gini pentru lungimea propozițiilor. O corelație directă între aceste două măsurători ne-a condus la eliminarea indicatorului Gini din analiza ulterioară, dat fiind o aparentă echivalență matematică între trăsături. Alte aspecte interesante observate ar fi corelația inversă dintre diversitatea lexicală a unui paragraf și rata cuvintelor funcționale, precum și conexiunea inversă dintre rata cuvintelor funcționale și densitatea punctuației.

Următorul pas al studiului nostru a fost cel de analiză a histogramelor aferente fiecărui indicator în parte, pentru fiecare set de date. Din vectorul de trăsături calculat, am extras indicatorii care au avut cele mai semnificative schimbări, cât și o parte din cei care nu au prezentat alterări vizibile. Cele mai proeminente modificări au fost observate în diversitatea lexicală, densitatea punctuației și rata cuvintelor funcționale.




Fig. 4 Histogramele indicatorului MATTR, pentru seturile de date “Human vs AI” și “Q1”

O primă schimbare observată este creșterea cu aproximativ o abatere standard a diversității lexicale atunci când măsurăm această trăsătură cu ajutorul MATTR. Această modificare este remarcată în toate cele trei seturi de date analizate. Concluzia pe care o putem extrage astfel este că există o creștere în diversitatea lexicală a paragrafelor, atât în abstractele post AI, cât și în textele parafrazate GenAI.




Fig. 5 Histogramele indicatorului de densitate a punctuației, pentru seturile de date “Q1” și “ArXiv”

O modificare care este observată doar la nivelul seturilor de date cu abstracte este densitatea punctuației. În era post-AI abstractele tind să conțină mai multe semne de punctuație în medie. Faptul că această schimbare apare strict la nivelul acestor două seturi de date ne spune că modificarea stilistică nu are o conexiune directă cu stilul de redactare al modelelor de limbaj.




Fig. 6 Histogramele ratei de cuvinte funcționale, pentru seturile de date “Human vs AI” și “ArXiv”

Reducerea ratei de cuvinte funcționale la nivelul celor trei seturi de date este un alt aspect remarcabil observat. Putem spune astfel că propozițiile abstractelor din era post-AI conțin mai multe cuvinte de conținut decât de legatură, fata de perioada pre-AI. De asemenea, putem afirma și faptul că textul GenAI tinde să conțină mai puține cuvinte funcționale / de legătură.

Următorul pas în analiza noastră a fost cel de reducere de dimensionalitate al datelor, pentru a vedea dacă discrepanțele dintre perioadele pre-AI și post-AI sunt vizibile în proiecțiile noastre bidimensionale și tridimensionale. Graficele Scree aferente analizei componentelor principale pot fi regăsite în anexa lucrării.




Fig. 7 Proiecția primelor două componente principale pentru seturile de date “Q1” și “ArXiv”

În toate cele trei seturi de date analizate, din proiecția primelor două componente principale rezultă o separare între perioadele/clasele analizate. Două grupări (engl. clusters) pot fi remarcate cu ușurință. Textele scrise în perioada post-AI sunt mai împrăștiate decât cele din era pre-AI. Acest comportament este de asemenea observat în setul de date “Human vs AI”.




Fig. 8 Proiecția primelor trei componente principale pentru seturile de date “Human vs AI” și “ArXiv”

Proiecțiile seturilor de date în trei dimensiuni capturează mai mult de 65% din variația observată în vectorii de trăsături. Dat fiind faptul că nivelul informațional al graficelor este mai mare, separările sunt și mai ușor de distins. Separările sunt cel mai proeminent observate în setul de date “ArXiv”.




Fig. 9 Contribuția fiecărei trăsături în construirea componentelor principale pentru setul de date “ArXiv”

Contribuția fiecărui indicator la formarea componentelor principale ne permite să observăm care indicatori sunt aceia care au influențat proiecțiile. Componenta care captează cea mai multă variație (~35%) este formată din cele trei componente analizate anterior (diversitate lexicală, rata cuvintelor funcționale și densitatea punctuației). A doua componentă este formată din caracteristicile care acționează la nivel sintactic (MDD, Burstiness) și cuprinde ~25% din variația datelor. Ultimul element analizat este concentrat pe captarea variației (~11%) la nivelul utilizării semnelor de punctuație (densitatea și diversitatea acestora). Considerăm interesant

faptul că fiecare component pare să fie atât de concentrat pe o categorie stilistică diferită, lucru ce ar putea indica faptul că schimbările de stil la nivelul diverselor categorii se desfășoară cu diferite amplitudini.



Fig. 10 Gap Statistics pentru setul de date "ArXiv" ne indică un K optim de 1 în procesul de clusterizare.

Pentru a identifica dacă există o separare relevantă din punct de vedere statistic al acestor grupări observate, am realizat pentru fiecare set de date Gap Statistics. Rezultatele acestor teste statistice, unde se compară grupările realizate cu ajutorul algoritmului de clusterizare K-Means, nu au fost în favoarea separării observabile atunci când punctele de date sunt colorate diferit în funcție de perioadă. Astfel, putem concluziona că separarea între perioadele analizate nu este demnă de analizat cu alte măsurători de validare a consistenței grupărilor precum Silhouette.

5. Discuții

Studiul nostru prezintă o analiză comprehensivă, dar are un număr de lacune de care ar trebui ținut cont. În primul rand, setul de date Wikipedia, deși este vast în numărul de puncte de date și utilizează un limbaj formal și sec, nu își găsește locul perfect în analiza abstractelor academice. Un set de date cu abstracte parafrazate cu un model de limbaj ar fi mai apt pentru o astfel de analiza. O alta lacuna a studiului nostru este lipsa de modele de clasificare care să măsoare performanța indicatorilor utilizați. Un alt aspect de care trebuie ținut cont este faptul că, deși această abordare permite un nivel înalt de interpretabilitate, modelele de limbaj actuale specializate pentru acest scop au abilitatea de a captura tipare mult mai subtile din textul analizat.

Am dori de asemenea să propunem multiple direcții în care, pe baza rezultatelor analizei noastre, cercetarea în acest domeniu ar putea continua. Utilizând acești indicatori nu ar trebui să fie foarte dificil să fie antrenat un model de tip K-Nearest-Neighbours (KNN), care are un mare potențial de a clasifica într-un mod interpretabil textele. De asemenea, ar putea fi interesantă crearea unui model de tip hibrid, care conține atât vectorul de tipare interpretabile, cât și un model de limbaj, în scopul clasificării textelor. Astfel, ar fi luate beneficiile interpretabilității indicatorilor și ar fi combinate cu abilitatea modelelor de limbaj de a captura tiparele textuale subtile.

6. Concluzii

Analiza noastră a ajuns astfel la un final armonios, punct din care putem extrage un set de concluzii privind întrebările de cercetare adresate la început. Graficele care nu au avut loc să apară în această analiză, dar prezintă interes, pot fi găsite în anexa lucrării.

Privind RQ1: Putem afirma că stilul de redactare în era post-AI al abstractelor s-a modificat într-un mod observabil. Schimbările s-au realizat într-o măsură vizibilă în cazul a 7 din cei 10 indicatori analizați (*MATTR*, *MTLD*, *Indexul Gini Simpson pentru diversitate lexicală*, *Burstiness*, *Densitatea punctuației*, *Function Word Ratio*, *Rata vocii pasive*). În era post-AI putem să ne așteptăm la texte cu o diversitate lexicală crescută, cu mai multe cuvinte de conținut și care utilizează același număr de semne de punctuație, dar mai des. De asemenea, dacă este utilizată vocea pasivă în paragraf, aceasta va fi regăsită mai puțin decât în era pre-AI.

Privind RQ2: Cele mai proeminente modificări stilistice sunt cele în diversitatea lexicală, cantitățile de punctuație utilizate și cantitatea de cuvinte funcționale. Schimbările în media indicatorilor variază de la o abatere standard până la două (în forma normalizată de scoruri Z).

Privind RQ3: O proporție mare din schimbările din era post-AI corespunde în detaliu cu cele asociate utilizării GenAI. Există totuși și excepții precum densitatea punctuației care nu prezintă modificări decât în stilul abstractelor, nu și al textelor parafrazate. Acest lucru ne poate indica faptul că nu trebuie să ne uităm la aceste rezultate ca fiind unele decisive privind cauza schimbărilor, ci ar trebui să ancorăm concluziile pe care le extragem în realitatea expusă de restul studiilor din domeniu.

Rezultatele lucrării au corespuns în proporție mare cu așteptările noastre, dar au existat situații în care ne-au surprins. Acestea se încadrează în mare măsură cu restul literaturii de specialitate și contribuie la perspectiva că în cazuri specifice interpretabilitatea datelor de intrare este importantă.

7. Bibliografie

Origine set de date Wikipedia parafrizat cu GPT-5-Nano

“Human vs AI”: <https://huggingface.co/datasets/gouwxsxander/wikipedia-human-ai>

OpenAI. (2022) *Introducing ChatGPT* <https://openai.com/index/chatgpt/>

Kumarage, Tharindu & Garland, Joshua & Bhattacharjee, Amrita & Trapeznikov, Kirill & Ruston, Scott & Liu, Huan. (2023). *Stylometric Detection of AI-Generated Text in Twitter Timelines*. 10.48550/arXiv.2303.03697.

https://www.researchgate.net/publication/373898266_Stylometric_Detection_of_AI-Generated_Text_in_Twitter_Timelines

Berriche, Larabi-Marie-Sainte. (2024). *Unveiling ChatGPT text using writing style*. Heliyon: https://www.sciencedirect.com/science/article/pii/S2405844024090078?getft_integrator=clarivate&pes=vor&utm_source=clarivate

Varga, Erika, Baksa, Attila (2025). *Syntactic comparison of human and AI-written scientific texts*. *Annales Mathematicae et Informaticae*. 61. pp. 248-260. ISSN 1787-6117

<https://publikacio.uni-eszterhazy.hu/8839/>

Guo, Shang, Clavel. (2025) *Benchmarking Linguistic Diversity of Large Language Models*. *Transactions of the Association for Computational Linguistics*: 13 1507–1526. doi:

<https://doi.org/10.1162/TACL.a.47>

<https://direct.mit.edu/tac/article/doi/10.1162/TACL.a.47/134150/Benchmarking-Linguistic-Diversity-of-Large>

Wikipedia. (2026) *Wikipedia:WikiProject AI Cleanup/Noticeboard*


https://en.wikipedia.org/wiki/Wikipedia:WikiProject_AI_Cleanup/Noticeboard

8. Anexă




Toate graficele sunt expuse în ordinea seturilor de date: “Q1”, “ArXiv”, “Human vs AI”.

Histograme



Dimensiunea 0 (MATTR)




Dimensiunea 1 (MTLD)






Dimensiunea 2 (Gini Simpson Lexical Diversity)







Dimensiunea 3 (Function Word Ratio)




Dimensiunea 4 (Burstiness)






Dimensiunea 5 (Sentence Length Gini Index)







Dimensiunea 6 (Punctuation Density)




Dimensiunea 7 (Punctuation Diversity)






Dimensiunea 8 (MDD)











Dimensiunea 9 (Rata vocii pasive)




Scree Plot




PCA 2D






PCA 3D



Human vs AI PCA
65.7% Explained Variance



PCA Analiza Componente



Gap Statistics

